

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Atelier Pratique : E-commerce de Cadeaux

Préparé par Emna Kaaniche

Année Universitaire : 2025-2026

Table des matières

Introduction Générale	2
Présentation du Dataset	2
1 Configuration et Architecture du Projet	3
1.1 Environnement de Travail	3
1.2 Structure de l'Arborescence	3
1.3 Reproductibilité et Dépendances	3
2 Exploration et Audit des Données (EDA)	4
2.1 Synthèse et Analyse des Features	4
2.1.1 Features Numériques (Variables 1 à 34)	4
2.1.2 Features Catégorielles (Variables 35 à 52)	4
2.2 Diagnostic Qualité et Audit des Données Brutes	4
2.2.1 Analyse des Anomalies et Manques	5
2.2.2 Audit de Multicolinéarité avant Nettoyage	5
3 Préparation et Transformation des Données	7
3.1 Nettoyage Initial et Parsing	7
3.2 Stratégie de Séparation (Train/Test Split)	7
3.3 Traitement des Valeurs Manquantes et Aberrantes	7
3.4 Encodage des Variables Catégorielles	7
3.5 Feature Engineering et Prévention du Data Leakage	7
3.6 Gestion de la Multicolinéarité et Mise à l'Échelle	8
4 Modélisation et Évaluation	9
4.1 Prédiction de l'Attrition (Classification)	9
4.1.1 Démarche de Modélisation et Optimisation	9
4.1.2 Comparaison des Modèles et Choix Final	9
4.1.3 Interprétabilité : Variables Décisives	10
4.1.4 Interprétation Métier et Recommandations Marketing	10
4.2 Prédiction de la Valeur Client (Régression)	11
4.2.1 Démarche de Modélisation et Optimisation	11
4.2.2 Évaluation des Performances	11
4.2.3 Interprétabilité : Variables Décisives	11
4.2.4 Interprétation Métier et Recommandations Marketing	12
4.3 Segmentation Clientèle (Clustering Non Supervisé)	12
4.3.1 Réduction de Dimensionnalité (ACP)	12
4.3.2 Détermination du Nombre de Clusters (K-Means)	13
4.3.3 Interprétation Métier et Recommandations Marketing	14
5 Déploiement et Recommandations	15
5.1 Mise en Production : Architecture et Interface Web	15
5.1.1 Logique Backend et Inférence	15
5.1.2 Interface Utilisateur et Restitution (Dashboard)	15
5.2 Synthèse et Recommandations Stratégiques (Métier)	16
5.2.1 Actions de Rétention et Valeur Client	16
5.2.2 Stratégies par Segments (Clustering)	16
Conclusion Générale	18

Introduction Générale

Le secteur du e-commerce est aujourd'hui marqué par une compétition intense où la compréhension fine de la donnée est devenue un levier de croissance indispensable. Dans ce contexte, ce projet s'inscrit dans une démarche de Data Science appliquée pour une entreprise spécialisée dans la vente en ligne de cadeaux.

L'enjeu n'est pas seulement technologique mais stratégique : il s'agit d'exploiter un historique transactionnel pour personnaliser les stratégies marketing, optimiser le chiffre d'affaires et, surtout, anticiper le départ des clients (phénomène de *Churn*).

Objectifs Pédagogiques et Techniques

- **Maîtrise du cycle de vie des données** : Couvrir l'intégralité de la chaîne de traitement, de l'exploration brute au déploiement.
- **Traitement de données imparfaites** : Résoudre des problèmes concrets de qualité de donnée (valeurs manquantes, aberrantes et déséquilibre de classes).
- **Modélisation Prédictive** : Appliquer des algorithmes de clustering et de classification pour segmenter la clientèle et prédire l'attrition.
- **Opérationnalisation** : Développer une interface utilisateur avec Flask pour rendre les modèles accessibles aux équipes métier.

Le Dataset : Une Vision à 360° du Client

L'étude repose sur une base de données complexe regroupant 52 caractéristiques (*features*) issues de transactions réelles et de données complémentaires. Ces variables permettent une analyse multidimensionnelle :

- **Indicateurs de Performance (RFM)** : Récence, fréquence et montants (moyen, std, min/max) des commandes.
- **Comportement et Engagement** : Préférences temporelles (jour, heure, saison), diversité du panier, et interaction avec le support client.
- **Profils Démographiques** : Âge, localisation géographique, genre et ancienneté du compte.

Ce rapport expose la démarche scientifique rigoureuse adoptée pour transformer ces données brutes en une solution prédictive déployée sous forme d'application web.

1 Configuration et Architecture du Projet

La réussite d'un projet de Machine Learning repose sur une organisation rigoureuse et un environnement de travail standardisé. Ce chapitre détaille l'architecture mise en place pour garantir la clarté et la reproductibilité de la chaîne de traitement.

1.1 Environnement de Travail

L'intégralité du développement a été réalisée avec l'éditeur **Visual Studio Code (VS Code)**. La gestion de version et le partage du code source sont assurés via un dépôt **GitHub**, facilitant ainsi le suivi des modifications et l'évaluation du projet.

1.2 Structure de l'Arborescence

Le projet suit une structure modulaire permettant de séparer les données, le code source et les livrables :

- **data/** : Centralise les ressources de données.
 - **raw/** : Données brutes originales (*retail_customers_COMPLETE_CATEGORICAL.xlsx*).
 - **processed/** : Données nettoyées après l'étape de prétraitement.
 - **train_test/** : Jeux de données splittés pour l'entraînement et le test.
- **notebooks/** : Contient les fichiers Jupyter utilisés pour l'exploration (EDA) et le prototypage.
- **src/** : Regroupe les scripts Python de production :
 - **preprocessing.py** : Pipeline de nettoyage et transformation.
 - **train_model.py** : Script d'entraînement des algorithmes.
 - **predict.py** : Module d'inférence pour les nouveaux clients.
 - **utils.py** : Fonctions utilitaires (visualisation, calculs).
- **models/** : Stockage des artefacts sauvegardés (modèles au format **.pkl** ou **.joblib**).
- **app/** : Contient l'application web développée avec le micro-framework **Flask**.

1.3 Reproductibilité et Dépendances

Pour garantir que l'environnement puisse être répliqué à l'identique, les outils suivants ont été utilisés :

- **Environnement Virtuel (venv)** : Isolation des dépendances du projet pour éviter les conflits système.
- **Fichier requirements.txt** : Liste exhaustive des bibliothèques nécessaires (*pandas, scikit-learn, flask, optuna*, etc.), générée via la commande **pip freeze**.
- **Documentation README.md** : Guide complet incluant la description du projet, les instructions d'installation et le mode d'emploi des scripts.

2 Exploration et Audit des Données (EDA)

Ce chapitre constitue une étape cruciale du projet. Conformément aux objectifs pédagogiques (Section 3 du document de référence), il vise à analyser la qualité et la structure des données brutes avant tout traitement. Nous y dressons un inventaire complet des variables disponibles et posons un diagnostic précis sur les anomalies détectées dans le jeu de données *dataset.xlsx*.

2.1 Synthèse et Analyse des Features

Le dataset mis à notre disposition est complexe, regroupant un total de 52 caractéristiques (*features*) issues de transactions réelles et de données complémentaires. Ces variables offrent une vision multidimensionnelle du parcours client. Nous les avons classées en deux catégories principales.

2.1.1 Features Numériques (Variables 1 à 34)

Ces 34 variables quantitatives permettent de mesurer l'activité et le comportement des clients. Elles incluent :

- **Identifiant** : `CustomerID` (unique par client).
- **Métriques RFM (Récence, Fréquence, Montant)** : Indispensables pour la segmentation (ex : `Recency`, `Frequency`, `MonetaryTotal`, `MonetaryAvg`). L'examen initial montre des intervalles préoccupants, notamment des montants négatifs (`MonetaryTotal` min à -5000 £) suggérant des erreurs ou des retours massifs.
- **Activité Transactionnelle** : Quantités d'articles (`TotalQuantity`), nombre de produits différents (`UniqueProducts`), de pays associés (`UniqueCountries`) et volume de lignes de transaction (`TotalTrans`).
- **Comportement et Engagement** : Préférences temporelles d'achat (`PreferredDay`, `PreferredHour`, `WeekendRatio`), ancienneté de la relation (`CustomerTenure`) et interactions avec le support client (`SupportTickets`, `Satisfaction`).
- **Métriques d'Erreur** : Compteurs de transactions annulées (`CancelledTrans`), lignes à prix nul (`ZeroPriceCount`) ou quantités négatives (`NegQtyCount`).
- **Démographie** : L'âge estimé du client (`Age`).
- **Variable Cible** : La colonne `Churn` (0 pour fidèle, 1 pour parti) est binaire.

2.1.2 Features Catégorielles (Variables 35 à 52)

Ces 18 variables qualitatives segmentent la clientèle selon différents critères :

- **Segmentations Prédéfinies** : `RFMSegment` (Champions, Dormants, etc.), `AgeCategory`, `SpendingCat` (VIP, Low) et `CustomerType`. Ces variables sont souvent dérivées des données numériques et nécessiteront un encodage ordinal ou "One-Hot" pour la modélisation.
- **Préférences Temporelles et Comportementales** : `FavoriteSeason`, `PreferredTime`, `WeekendPref`, taille habituelle du panier (`BasketSize`) et diversité des achats (`ProdDiversity`).
- **Données Démographiques et Géographiques** : `Region` (8 valeurs dont UK, Europe), `Country` (plus de 37 pays), `Gender` et `LoyaltyLevel`.
- **Statuts et Données Brutes** : État du compte (`AccountStatus`), abonnement newsletter (`Newsletter`), adresse IP (`LastLoginIP`) et date d'inscription (`Regist Date`).

2.2 Diagnostic Qualité et Audit des Données Brutes

L'objectif pédagogique de cet atelier est de travailler sur une base "intentionnellement imparfaite". Notre audit a révélé plusieurs problèmes de qualité majeurs décrits dans la section 5 du document de référence, que nous devons impérativement résoudre lors de la phase de préparation.

2.2.1 Analyse des Anomalies et Manques

- **Valeurs Manquantes Importantes** : La variable démographique cruciale **Age** présente un taux de valeurs manquantes (NaN) de 30%, ce qui nécessitera une stratégie d'imputation avancée (moyenne, médiane ou KNN).
- **Valeurs Aberrantes (Outliers)** : Les variables liées à la satisfaction (**Satisfaction**) et aux tickets de support (**SupportTickets**) contiennent des valeurs incohérentes (ex : -1, 99, 999) hors des intervalles logiques. Ces données bruitent les modèles et devront être corrigées ou écartées.
- **Incohérences de Format** : La date d'inscription (**Regist Date**) est stockée sous forme de texte avec des formats hétérogènes (ex : "12/03/10" format UK, "2010-03-12" format ISO), rendant l'exploitation directe impossible sans un parsing rigoureux.
- **Features Inutiles** : La variable **NewsletterSubscribed** est constante à 100% (toujours "Yes"), n'apportant aucune information discriminante. Elle doit être supprimée.
- **Déséquilibre des Classes** : La variable cible **Churn** présente un fort déséquilibre, la classe "parti" étant minoritaire. Ce déséquilibre constitue un défi majeur pour l'apprentissage des algorithmes de classification et nécessitera des techniques de rééquilibrage.

2.2.2 Audit de Multicolinéarité avant Nettoyage

Pour visualiser l'état initial des relations entre les variables numériques avant tout traitement de nettoyage ou d'imputation, nous avons généré une matrice de corrélation des features numériques brutes (Figure 1).

Cette visualisation initiale, bien que bruitée par les valeurs aberrantes et les données brutes, confirme nos intuitions et identifie des problèmes de multicolinéarité :

- **Forte redondance entre métriques RFM** : Des corrélations très élevées (proches de 1, zones rouge foncé) apparaissent entre **MonetaryTotal**, **MonetaryAvg**, **Frequency** et **TotalQuantity**. Conserver toutes ces variables dans une régression risquerait de fausser les résultats.
- **Impact des valeurs aberrantes** : On observe des motifs de corrélation étranges liés aux quantités négatives (**NegQtyCount**) et transactions annulées (**CancelledTrans**) qui se corrélaient avec les montants minimaux (**MonetaryMin**), confirmant l'impact des retours mal gérés sur les données financières brutes.
- **Redondance transactionnelle** : Le nombre total de lignes (**TotalTrans**) est fortement lié au nombre de produits uniques (**UniqueProducts**) et de descriptions uniques (**UniqueDesc**).

L'ensemble de ces constats impose une phase de préparation de données rigoureuse, détaillée dans le chapitre suivant.




FIGURE 1 – Matrice de corrélation des features numériques avant nettoyage. Les fortes corrélations (rouge) et anti-corrélations (bleu) mettent en évidence des redondances massives et l'impact des valeurs aberrantes brutes.

3 Préparation et Transformation des Données

Suite au diagnostic de notre jeu de données, ce chapitre détaille le pipeline de prétraitement mis en œuvre pour transformer les données brutes en un format optimal pour l'apprentissage automatique. L'ensemble de ce processus a été codé dans le script `preprocessing.py` en respectant scrupuleusement les bonnes pratiques pour éviter toute fuite de données (*data leakage*).

3.1 Nettoyage Initial et Parsing

La première étape, effectuée avant toute séparation des données, a consisté à normaliser la structure du dataset :

- **Suppression des variables constantes** : La colonne `NewsletterSubscribed` (et ses variantes), n'ayant qu'une seule valeur, a été retirée car elle n'apporte aucun pouvoir prédictif.
- **Correction des types** : La variable `MonetaryTotal` contenait des dates parasites qui ont été converties en valeurs manquantes (NaN) pour être traitées ultérieurement, garantissant un type strictement numérique.
- **Parsing des dates** : La variable texte `RegistrationDate` a été convertie en format `datetime`, ce qui a permis d'extraire de nouvelles caractéristiques temporelles (`RegYear`, `RegMonth`, `RegDay`, `RegWeekday`) avant d'être supprimée.

3.2 Stratégie de Séparation (Train/Test Split)

Pour évaluer la performance réelle de nos futurs modèles, les données ont été divisées en un ensemble d'entraînement (80%) et un ensemble de test (20%). Afin de pallier le déséquilibre de la variable cible `Churn`, nous avons utilisé une séparation stratifiée (`stratify=y`). **Toutes les étapes d'imputation et de transformation suivantes ont été "ajustées" (*fit*) uniquement sur l'ensemble d'entraînement**, puis appliquées à l'ensemble de test, prévenant ainsi toute fuite d'information.

3.3 Traitement des Valeurs Manquantes et Aberrantes

- **Imputation** : Les valeurs manquantes numériques ont été remplacées par la médiane (plus robuste face aux valeurs extrêmes que la moyenne), tandis que les variables catégorielles ont été complétées par la valeur la plus fréquente (mode).
- **Gestion des Outliers** : Pour limiter l'impact des valeurs aberrantes identifiées lors de l'EDA, nous avons appliqué une technique de *clipping* (écrêtage) en limitant les valeurs numériques aux 1^{er} et 99^{ème} centiles de la distribution d'entraînement.

3.4 Encodage des Variables Catégorielles

Les algorithmes nécessitant des entrées numériques, nous avons appliqué plusieurs stratégies d'encodage selon la nature des variables :

- **Target Encoding** : Utilisé pour la variable à forte cardinalité `Country`, remplaçant chaque pays par la moyenne de la cible (`Churn`).
- **Encodage Ordinal** : Appliqué aux variables possédant un ordre inhérent, telles que `SpendingCat`, `LoyaltyLevel` ou `BasketSize`.
- **One-Hot Encoding** : Appliqué aux variables nominales (`Region`, `RFMSegment`, etc.) en ne conservant que les 10 catégories les plus fréquentes pour éviter une explosion de la dimensionnalité.

3.5 Feature Engineering et Prévention du Data Leakage

Pour enrichir la capacité d'apprentissage du modèle, de nouvelles variables ont été créées à partir des données existantes :

- **MonetaryPerDay** : Ratio des dépenses totales sur la récence.
- **AvgBasketValue** : Valeur moyenne du panier ($\text{MonetaryTotal} / \text{Frequency}$).
- **TenureRatio** : Ratio d'activité récente par rapport à l'ancienneté globale.

En parallèle, une étape critique a consisté à supprimer les variables **ChurnRisk** et **AccountStatus**. Ces données constituaient une fuite d'information majeure (Data Leakage) puisqu'elles sont des conséquences directes ou des proxys évidents de la variable cible à prédire.

3.6 Gestion de la Multicolinéarité et Mise à l'Échelle

Pour corriger les fortes corrélations observées lors de l'exploration initiale, nous avons identifié les paires de variables ayant un coefficient de corrélation de Pearson supérieur à 0,8 et supprimé l'une des deux.

Comme l'illustre la figure 2, cette opération a permis de nettoyer la matrice de corrélation, réduisant le bruit et la redondance (notamment entre les métriques RFM et transactionnelles).




FIGURE 2 – Matrice de corrélation après nettoyage et suppression des variables hautement corrélées. La redondance de l'information a été drastiquement réduite.

Enfin, toutes les caractéristiques ont été standardisées (moyenne de 0 et écart-type de 1) à l'aide d'un **StandardScaler**. Le modèle est ainsi prêt à être entraîné de manière stable et performante.

4 Modélisation et Évaluation

Après avoir rigoureusement nettoyé et préparé nos données, ce chapitre aborde le cœur prédictif du projet. Notre démarche de modélisation suit une approche itérative et comparative. Nous commençons par la problématique principale du projet : la prédiction du départ des clients (Classification du Churn).

4.1 Prédiction de l'Attrition (Classification)

L'objectif ici est d'identifier les clients susceptibles de quitter la plateforme ($\text{Churn} = 1$). La variable cible étant déséquilibrée, nous avons utilisé des métriques adaptées telles que le F1-Score et l'aire sous la courbe ROC (ROC-AUC), et configuré nos algorithmes avec l'argument `class_weight='balanced'` lorsque cela était possible.

4.1.1 Démarche de Modélisation et Optimisation

Nous avons évalué et comparé trois algorithmes de classification, implémentés dans le script `train_model.py` :

1. **Régression Logistique** : Utilisée comme modèle de base (*baseline*) pour obtenir une première estimation linéaire des performances.
2. **Forêt Aléatoire (Random Forest)** : Un algorithme ensembliste robuste face au surapprentissage et interprétable.
3. **Gradient Boosting** : Une méthode d'ensemble séquentielle souvent très performante mais gourmande en ressources.

Pour maximiser les performances des modèles avancés, nous avons procédé à un réglage fin des hyperparamètres à l'aide de `GridSearchCV`. Cette technique a permis de tester exhaustivement différentes combinaisons (comme le nombre d'arbres `n_estimators` ou la profondeur maximale `max_depth`) en utilisant une validation croisée à 5 plis (*5-fold Cross-Validation*), garantissant ainsi la robustesse et la généralisation de nos modèles.

4.1.2 Comparaison des Modèles et Choix Final

La figure 3 illustre les performances comparées des trois algorithmes testés.




FIGURE 3 – Comparaison des performances (ROC-AUC et F1-Score) des modèles de classification.

Bien que le Gradient Boosting affiche d'excellentes capacités prédictives, ****notre choix final s'est porté sur le Random Forest optimisé****. Ce modèle présente des performances très compétitives tout en étant beaucoup plus léger et rapide à exécuter (*computationally efficient*) que le Gradient Boosting. Ce compromis est idéal pour un déploiement en production via notre API Flask. Le modèle final a ainsi été sauvegardé au format `.pkl` à l'aide de la bibliothèque `joblib`.

4.1.3 Interprétabilité : Variables Décisives

L'un des avantages majeurs du Random Forest est sa capacité à évaluer l'importance de chaque caractéristique dans le processus de décision (Figure 4).




FIGURE 4 – Top des variables les plus importantes (Feature Importance) identifiées par le modèle Random Forest.

Cette analyse est cruciale pour le métier, car elle met en évidence les facteurs comportementaux et transactionnels qui influencent le plus le risque d'attrition. Ces indicateurs clés permettront à l'équipe marketing de cibler précisément ses futures campagnes de rétention.

4.1.4 Interprétation Métier et Recommandations Marketing

L'analyse des variables décisives met en lumière les principaux signaux faibles annonciateurs d'un départ. La traduction de ces indicateurs prédictifs en stratégies marketing permet à l'entreprise d'agir de manière proactive :

- **Score de Risque en Temps Réel** : L'objectif est d'intégrer directement le modèle prédictif (via l'API Flask) au CRM de l'entreprise. Dès qu'un client présente une probabilité de *Churn* (score de risque) supérieure à 0,5, une alerte est automatiquement remontée aux conseillers clientèle pour une prise en charge prioritaire.
- **Action Anti-Attrition Ciblée** : Pour les clients identifiés comme étant à risque, il est recommandé de déclencher une campagne automatisée incluant un bon d'achat de type "On vous regrette déjà". Afin de raviver l'engagement de manière pertinente, cette offre sera ciblée spécifiquement sur des catégories de produits que le client n'a pas encore testées. Cette action vise directement à augmenter la diversité de son panier (*ProductDiversity*), un levier identifié par le modèle pour fidéliser la clientèle.

4.2 Prédiction de la Valeur Client (Régression)

Si la classification nous permet d'anticiper le départ d'un client, la régression nous offre la possibilité d'estimer sa valeur financière pour l'entreprise. L'objectif de cette étape, implémentée dans le script `regression.py`, est de prédire le montant total dépensé par un client (`MonetaryTotal`).

4.2.1 Démarche de Modélisation et Optimisation

Pour cette tâche, nous avons veillé à exclure la variable `Churn` (afin d'éviter toute fuite de données lors de la prédiction de la valeur future) ainsi que les identifiants non pertinents. Notre choix s'est porté sur l'algorithme **Random Forest Regressor**, particulièrement adapté pour modéliser des relations non linéaires complexes.

À l'instar de la classification, le modèle a été rigoureusement optimisé à l'aide de `GridSearchCV`. Nous avons exploré différentes combinaisons d'hyperparamètres (nombre d'arbres `n_estimators`, profondeur maximale `max_depth`, et nombre minimum d'échantillons pour diviser un nœud `min_samples_split`) en utilisant une validation croisée à 3 plis (*3-fold Cross-Validation*).

4.2.2 Évaluation des Performances

Les performances du meilleur modèle ont été mesurées sur l'ensemble de test à l'aide de métriques standards de régression :

- **Score R^2** : Permet de quantifier la part de variance du montant total (`MonetaryTotal`) qui est expliquée par notre modèle.
- **MAE (Mean Absolute Error)** : Représente l'erreur moyenne de prédiction en valeur absolue, nous donnant une idée de l'erreur typique en devise (£).
- **RMSE (Root Mean Squared Error)** : Pénalise fortement les grandes erreurs de prédiction, offrant une vision plus stricte de la robustesse globale.

4.2.3 Interprétabilité : Variables Décisives

L'analyse de l'importance des variables (Figure 5) révèle les leviers qui impactent le plus la valeur financière générée par un client.




FIGURE 5 – Top 10 des variables les plus importantes pour la prédiction du montant total (Random Forest Regressor).

4.2.4 Interprétation Métier et Recommendations Marketing

La capacité de prédire précisément le **MonetaryTotal** est un atout stratégique pour l'optimisation du Retour sur Investissement (ROI) :

- **Allocation Stratégique du Budget** : En combinant la probabilité de départ (issue de la classification) avec le revenu estimé (issu de la régression), l'entreprise peut évaluer la Valeur Vie Client (*Customer Lifetime Value - CLV*).

Recommendation Marketing : Allouer le budget d'actions promotionnelles (appels premium, réductions massives) en priorité absolue aux clients ayant un montant prédit très élevé mais un risque d'attrition critique. Les clients à faible potentiel de revenus ne devront recevoir que des campagnes automatisées à coût nul.

- **Leviers de Vente Incitative (Up-Selling)** : Les variables identifiées comme cruciales par le modèle (souvent liées au volume ou à la récurrence) dictent le comportement d'achat à encourager.

Recommendation Marketing : Mettre en place des mécanismes de recommandation personnalisée et de lots promotionnels (*Bundles*) lors de la validation du panier, afin de maximiser mécaniquement les indicateurs qui tirent la valeur globale vers le haut.

4.3 Segmentation Clientèle (Clustering Non Supervisé)

Afin de compléter notre compréhension du comportement client au-delà de la prédiction pure, nous avons mis en place une approche d'apprentissage non supervisé détaillée dans le script `clustering.py`. L'objectif est d'identifier des groupes naturels (segments) de clients partageant des habitudes d'achat similaires, sans utiliser la variable cible **Churn** ni les segmentations métiers préexistantes (afin d'éviter tout biais).

4.3.1 Réduction de Dimensionnalité (ACP)

Travailler avec un grand nombre de variables (plus de 50) peut dégrader les performances des algorithmes de clustering en raison du "fléau de la dimension". Après avoir standardisé nos données

numériques (`StandardScaler`), nous avons appliqué une **Analyse en Composantes Principales (ACP)**.

L'objectif de l'ACP est de réduire le nombre de dimensions tout en conservant un maximum d'information. Comme l'illustre la figure 6, nous avons paramétré le modèle pour conserver **95% de la variance expliquée**, ce qui permet de compresser drastiquement l'espace des caractéristiques tout en gardant l'essence des comportements d'achat.




FIGURE 6 – Variance expliquée cumulée par l'ACP. L'objectif de 95% de variance est atteint avec un nombre réduit de composantes principales.

4.3.2 Détermination du Nombre de Clusters (K-Means)

Une fois les données projetées dans ce nouvel espace réduit, nous avons appliqué l'algorithme **K-Means**. Le défi principal de cet algorithme est de définir en amont le nombre optimal de groupes (K).

Pour ce faire, nous avons évalué les performances pour différentes valeurs de K (généralement via la méthode du coude ou le score de silhouette), comme le montre la figure 7. L'analyse de ces métriques nous a conduits à sélectionner de manière optimale **$K = 4$ clusters**.




FIGURE 7 – Évaluation du nombre optimal de clusters (K). Le point d'inflexion justifie notre choix de diviser la clientèle en 4 segments distincts.

4.3.3 Interprétation Métier et Recommandations Marketing

Le profilage des 4 clusters obtenus permet de dégager des stratégies d'action très spécifiques, directement exploitables par les équipes de vente et de marketing :

- **Cluster 1 (Les VIPs / Champions)** : Ce groupe rassemble les clients générant la plus forte valeur financière et ayant une fréquence d'achat élevée.
Recommandation Marketing : Créer un **Programme de fidélité "Platinum"**. Ces clients doivent bénéficier d'un traitement exclusif, tel qu'un accès prioritaire aux nouvelles collections de cadeaux ou une ligne de support client dédiée, afin de consolider leur attachement à la marque.
- **Cluster 3 (Les Clients Réguliers / Engagés)** : Il s'agit d'une base de clients solides qui achètent régulièrement sans pour autant atteindre les montants des VIPs.
Recommandation Marketing : Lancer des **Campagnes de parrainage**. L'objectif est d'utiliser leur satisfaction récurrente pour les transformer en ambassadeurs de la marque, en leur offrant des récompenses (bons d'achat) s'ils amènent de nouveaux clients sur la plateforme.
- **Clusters 2 et 4 (Les Occasionnels et Clients à Risque)** : Ces groupes nécessiteront des campagnes de *nurturing* (emails éducatifs sur la diversité du catalogue) et des offres promotionnelles ciblées pour relancer leur activité et augmenter la taille de leur panier moyen.

5 Déploiement et Recommandations

L'aboutissement d'un projet de Machine Learning ne réside pas uniquement dans l'obtention de métriques performantes, mais dans la capacité à rendre ces modèles exploitables par les utilisateurs finaux (équipes marketing et commerciales). Ce dernier chapitre détaille la mise en production de notre solution et synthétise nos recommandations stratégiques.

5.1 Mise en Production : Architecture et Interface Web

Pour rendre nos modèles accessibles de manière interactive, nous avons développé une application web en utilisant **Flask**, un micro-framework Python reconnu pour sa légèreté et sa parfaite synergie avec l'écosystème de *Data Science* (Scikit-Learn, Pandas).

5.1.1 Logique Backend et Inférence

L'architecture de déploiement, orchestrée par les scripts `app.py` et `predict.py`, repose sur plusieurs piliers techniques :

- **Centralisation des Artefacts** : Au démarrage de l'application, l'ensemble des modèles entraînés (*Random Forest Classifier*, *Random Forest Regressor*, *K-Means*) et des outils de transformation (*StandardScaler*, *PCA*) sont chargés en mémoire via la bibliothèque `joblib`.
- **Reproductibilité du Pipeline** : Lorsqu'un utilisateur saisit les données d'un nouveau client, ces dernières subissent rigoureusement les mêmes étapes de nettoyage et de transformation (encodage, normalisation) que celles définies lors de l'entraînement, évitant ainsi toute erreur d'inférence.
- **Accessibilité Multicanal** : L'application expose une route principale (/) offrant une interface graphique intuitive, mais intègre également un point de terminaison API (`/api/predict`) permettant de renvoyer les prédictions au format JSON pour une future intégration directe au CRM.

5.1.2 Interface Utilisateur et Restitution (Dashboard)

L'expérience utilisateur a été conçue pour être fluide et informative. La figure 8 présente le formulaire initial de saisie.

The screenshot shows a web application interface for client analysis. The main form, titled 'Profil client', is divided into several sections: 'DONNÉES RFM' (with fields for Récence, Total Dépense, Écart-type Dépenses, Fréquence, Moyenne par Commande, and Total Articles), 'PROFIL CLIENT' (with fields for Ancienneté, Âge Estimé, Satisfaction, Tickets Support, Segment RFM, and Niveau Dépense), and 'COMPORTEMENT D'ACHAT' (with fields for Transactions Annulées, Taux de Retour, Produits Uniques, Ratio Weekend, Total Transactions, and Factures Distinctes). To the right of the form, there's a 'Modèles chargés' section listing three models: 'Churn (classification)', 'Segmentation (K-Means)', and 'Valeur client (régression)'. Below this is a 'Résultats de l'analyse' section with a magnifying glass icon and a prompt to fill the form and click 'Analyser ce client pour obtenir les résultats.' At the bottom of the form is a blue button labeled 'Analyser ce client'.

FIGURE 8 – Interface web Flask : Formulaire de saisie des informations client.

Une fois les données soumises, l'application exécute les trois modèles simultanément. La figure 9 illustre le tableau de bord de restitution, qui fournit une analyse à 360 degrés du profil client.




FIGURE 9 – Tableau de bord des résultats : Affichage du risque de churn, de la valeur prédite et du segment (Cluster), accompagné des recommandations dynamiques.

5.2 Synthèse et Recommandations Stratégiques (Métier)

La combinaison de nos trois approches algorithmiques permet de passer d'une posture réactive à une stratégie marketing **proactive et hyper-personnalisée**.

5.2.1 Actions de Rétention et Valeur Client

- **Score de Risque en Temps Réel** : L'intégration du modèle au CRM permet d'alerter immédiatement les conseillers dès qu'un score de *Churn* dépasse 0.5.
- **Optimisation du Budget Marketing** : En croisant la probabilité de départ avec le `MonetaryTotal` prédit par la régression, l'entreprise peut prioriser ses efforts de rétention sur les clients à plus forte valeur.
- **Action Anti-Attrition Ciblée** : Pour les clients à risque, l'envoi d'un bon d'achat "On vous regrette déjà" doit être couplé à des suggestions de catégories de produits non encore testées par le client, afin de stimuler la *ProductDiversity*.

5.2.2 Stratégies par Segments (Clustering)

- **Pour les VIP (Cluster 1)** : Mise en place d'un programme de fidélité "Platinum" offrant un accès prioritaire aux nouvelles collections et des avantages exclusifs pour consolider leur loyauté.
- **Pour les Clients Engagés (Cluster 3)** : Lancement de campagnes de parrainage. Ces clients réguliers sont les meilleurs candidats pour devenir des ambassadeurs de la marque en échange de récompenses ciblées.

- **Pour les Clients Occasionnels** : Utilisation de campagnes de *nurturing* basées sur les variables décisives identifiées par les modèles pour les inciter à augmenter leur fréquence d'achat.

Conclusion Générale

Le présent projet, consacré à l'analyse comportementale de la clientèle retail, s'inscrit dans une démarche globale de transformation de la donnée brute en intelligence décisionnelle. À travers les différentes étapes de ce travail, nous avons pu aborder la complexité d'un pipeline de *Data Science* complet, allant du nettoyage rigoureux des données jusqu'au déploiement d'une solution interactive.

Synthèse des Travaux Réalisés

L'objectif premier était de comprendre et de prédire les comportements d'achat pour optimiser la stratégie de fidélisation. La phase de préparation des données a été cruciale : la gestion des valeurs aberrantes, le traitement du *data leakage* et l'ingénierie des caractéristiques (*feature engineering*) ont permis de transformer une base de données transactionnelle en un ensemble de 52 variables prédictives robustes.

Sur le plan de la modélisation, nous avons adopté une approche multidimensionnelle :

- **La Classification** nous a permis d'identifier avec précision les signaux précurseurs du *Churn*. Grâce à l'optimisation des modèles de *Random Forest*, l'entreprise dispose désormais d'un score de risque fiable pour agir avant le départ du client.
- **La Régression** a apporté une dimension financière indispensable en estimant la valeur monétaire potentielle de chaque client, permettant ainsi une allocation budgétaire marketing plus rationnelle et basée sur le retour sur investissement (ROI).
- **Le Clustering**, soutenu par une réduction de dimensionnalité via l'ACP, a révélé l'hétérogénéité de la base client, passant d'une masse uniforme à quatre segments distincts (VIP, Engagés, Occasionnels, À risque) nécessitant chacun une approche marketing spécifique.

Apports Métiers et Valeur Ajoutée

La concrétisation de ces modèles sous forme d'application web avec le micro-framework **Flask** constitue l'un des points forts de ce projet. Cet outil ne se contente pas de fournir des probabilités ; il démocratise l'accès au Machine Learning pour les équipes opérationnelles en offrant une interface de prédiction en temps réel. Les recommandations marketing générées dynamiquement permettent de transformer l'analyse statistique en actions concrètes : programmes de fidélité Platinum pour les VIP, parrainage pour les ambassadeurs, ou campagnes de relance ciblées sur la diversité des produits pour les clients en perte de vitesse.

Limites et Perspectives

Bien que les résultats obtenus soient performants, ce travail ouvre la voie à plusieurs pistes d'amélioration.

1. **Enrichissement des données** : L'intégration de données exogènes, telles que les interactions sur les réseaux sociaux ou l'analyse de sentiment des avis clients, permettrait d'affiner encore davantage la prédiction du *Churn*.
2. **Deep Learning et Temps Réel** : L'utilisation de réseaux de neurones récurrents (RNN) ou de modèles basés sur les Transformers pourrait permettre de capturer des séquences temporelles d'achat plus complexes.
3. **Moteur de Recommandation** : Une extension naturelle de ce projet serait le développement d'un système de recommandation de produits spécifique (*Collaborative Filtering*), intégré à l'interface Flask pour suggérer l'article exact capable de maximiser la satisfaction client.

Mots de la Fin

En conclusion, ce projet démontre que le Machine Learning est un levier de croissance incontournable dans le secteur du retail. En alliant rigueur statistique et vision métier, nous avons construit une

solution capable non seulement de prédire l'avenir, mais surtout de l'influencer positivement. Cette expérience confirme que la valeur de la donnée ne réside pas dans sa quantité, mais dans la pertinence des algorithmes et des stratégies qu'elle permet de déployer au service de l'expérience client.